

Universidade Federal de Minas Gerais
Escola de Engenharia
Curso de Graduação em Engenharia de Controle e Automação

**Análise e classificação de sinais de eletrorretinograma
utilizando regressão logística aplicada a parâmetros
morfológicos e estatísticos**

Júlia de Castro

Orientador: Prof. Danilo Barbosa Melges

Belo Horizonte, Novembro de 2025

Monografia

Análise e classificação de sinais de eletrorretinograma utilizando regressão logística aplicada a parâmetros morfológicos e estatísticos

Monografia submetida à banca examinadora designada pelo Colegiado Didático do Curso de Graduação em Engenharia de Controle e Automação da Universidade Federal de Minas Gerais, como parte dos requisitos para aprovação na atividade Projeto Final de Curso II.

Belo Horizonte, Novembro de 2025

Resumo

O eletrorretinograma (ERG) é um exame oftalmológico complementar que permite realizar uma avaliação funcional de células da retina por meio da resposta a estímulos visuais por *flash* (FERG) ou por padrões espaciais (PERG, de *pattern* ERG). O sinal de PERG, na visão normal, apresenta as seguintes componentes: um vale em aproximadamente 35 ms (N35) pós-estímulo, um pico entre 45 e 60 ms (P50) e um vale entre 90 e 100 ms (N95). Na clínica, costuma-se avaliar os valores de amplitude e tempo implícito de cada componente para determinar a saúde do sistema visual. Este trabalho teve como objetivo analisar e classificar sinais de PERG a partir da aplicação de técnicas de processamento de sinais e Regressão Logística (RL), com base em parâmetros morfológicos (PM) e estatísticos (PE). Os PM foram valores de amplitude e latência (tempo implícito) de N35, P50 e N95. Os PE foram variância, curtose, assimetria e entropia calculadas sobre a distribuição dos valores de amplitude do sinal de PERG. Foram utilizados sinais da base de dados pública PERG-IOBA (Physionet), composta por registros de indivíduos com visão normal e com diferentes disfunções visuais. Neste trabalho, foram empregados os sinais de PERG de três grupos: indivíduos com visão normal, com distrofia macular (DM) e com retinite pigmentosa (RP). Inicialmente, a flutuação de linha de base foi removida (*detrend*), seguida por uma filtragem com passa-baixas Butterworth de segunda ordem, fase nula e frequência de corte em 90 Hz. Posteriormente, foram calculados os PM e PE. A classificação foi realizada por meio de RL aplicada aos parâmetros calculados em 3 situações distintas: i) somente PM; ii) somente PE; e iii) PM+PE. Os dados foram divididos aleatoriamente em 80% para treinamento e 20% para teste. Foram executadas 100 rodadas de classificação e calculada a acurácia média. Na classificação com PM esse valor foi de cerca de 80% nas diferenciações normal vs DM e normal vs RP, mas de apenas 53% na discriminação entre os traçados de pacientes com disfunções visuais (DM vs RP). Resultados similares foram encontrados para a classificação com PM+PE. Por outro lado, as acurácias médias de classificação com PE foram de cerca de 70% para normal vs DM, 76% para normal vs RP e 53% para DM vs RP. Assim, pode-se considerar promissora a classificação automática entre registros normais e patológicos de PERG utilizando a metodologia proposta, sugerindo-se, no entanto, estudar o emprego de outros parâmetros, como os obtidos no domínio da frequência e de tempo-frequência, a fim de melhorar a acurácia. Por outro lado, não foi possível distinguir entre os grupos patológicos (DM vs RP) para nenhum conjunto de parâmetros utilizados, sendo necessária maior investigação visando a utilização da classificação automática para diagnóstico diferencial.

Abstract

The electroretinogram (ERG) is an ophthalmological test that enables functional assessment of retinal cells through their response to visual stimuli delivered either by flashes (FERG) or by spatial patterns (PERG, pattern ERG). In normal vision, the PERG signal typically presents the following components: a valley at approximately 35 ms (N35) post-stimulus, a peak between 45 and 60 ms (P50), and a valley between 90 and 100 ms (N95). In clinical practice, the amplitude and implicit time of each component are generally evaluated to determine the health of the visual system. The aim of this study was to analyze and classify PERG signals using signal processing techniques and logistic regression (LR), based on morphological parameters (MP) and statistical parameters (SP). The MPs consisted of amplitude and latency (implicit time) values of N35, P50, and N95. The SPs consisted of variance, kurtosis, and skewness calculated from the amplitude distribution of the entire PERG signal, as well as amplitude entropy. The PERG signals analyzed belong to the public PERG-IOBA database (Physionet), which is composed of recordings from individuals with normal vision and with different visual dysfunctions. In this study, PERG signals from three groups were used: individuals with normal vision, with macular dystrophy (MD) and with retinitis pigmentosa (RP). Initially, baseline fluctuation was removed (detrending), followed by second-order zero-phase Butterworth low-pass filtering with a 90Hz cutoff frequency. Subsequently, all MPs and SPs were computed. Signal classification was performed using LR applied to the calculated parameters in three different scenarios: (i) MPs only; (ii) SPs only; and (iii) MP+SP. The data were randomly divided into 80% for training and 20% for testing. Then, 100 classification rounds were executed, and the mean accuracy was computed. For the MP-based classification, mean accuracy was about 80% for the distinctions normal vs. MD and normal vs. RP, but only 53% for discriminating between patients with visual dysfunctions (MD vs. RP). Very similar results were found for the MP+SP classification. On the other hand, mean accuracies using SPs were about 70% for normal vs. MD, 76% for normal vs. RP, and 53% for MD vs. RP. Thus, the possibility of automatic classification between normal and pathological PERG recordings using the proposed methodology can be considered promising. However, it is suggested that other parameters—such as those obtained in the frequency and time–frequency domains—should be investigated to improve accuracy. Conversely, it was not possible to distinguish between the pathological groups (MD vs. RP) using any of the parameter sets, indicating the need for further investigation regarding the use of automatic classification for differential diagnosis.

Agradecimentos

Agradeço a Deus, pela sabedoria e força concedidas ao longo desta jornada. À minha família, pelo apoio e incentivo constantes, e aos amigos, pelo companheirismo durante todo o percurso acadêmico. Aos professores da graduação, pelo compartilhamento de conhecimento e contribuição para minha formação. Em especial, ao professor Danilo, pela orientação, disponibilidade e dedicação durante o desenvolvimento deste trabalho. Agradeço também ao grupo de pesquisa da Universidade de Valladolid, na Espanha, pela disponibilização pública da base de dados PERG-IOBA, essencial para a realização deste estudo.